

# Unicode

---

**Az Unicode univerzális karakterkódolási szabvány írott karakterekhez és szöveghez.** Lefedi a világ összes modern és ősi nyelvének összes karakterét. Tartalmaz továbbá műszaki szimbólumokat, írásjeleket és sok más olyan karaktert, melyet írott szövegben használnak. Az Unicode széles körben használt és támogatott karakterkódolási szabvány.

## Alapvető fogalmak

**Kódtér:** A karaktereket kódoló egész számok tartománya

**Kódpont:** A kódtér egy eleme, egy karaktert kódoló egész szám.

**Basic Multilingual Plane (BMP):** Az első 65 536 kódpontot (U+0000-U+FFFF) tartalmazó sík (0. sík). A BMP-be tartozik a Unicode karakterek többsége szinte minden szöveges adat esetén. \

## Karakterkódolások

A szabvány által megadott karakterkódolások

*Mindhárom karakterkódolással ábrázolható valamennyi Unicode karakter.* Az UTF a Unicode transzformációs formátum (Unicode transformation format) rövidítése.

### UTF-8

*A kódpontok ábrázolása 1-4 byte-on történik (változó szélességű kódolás).*

- Az U+0000-U+007F tartományba eső kódpontokat egy byte ábrázolja (128 ASCII karakter).
- Az U+0080-U+07FF tartományba eső kódpontokat 2 byte ábrázolja
- A BMP összes további kódpontját 3 byte ábrázolja.
- A BMP-n kívüli kódpontokat 4 byte ábrázolja.

Egy kódpontot ábrázoló byte-sorozat első byte-ja meghatározza a sorozat hosszát (egyszerű feldolgozhatóság). A használt byte-ok számának tekintetében a legtömörebb kódolás. Kevésbé hatékony kelet-ázsiai írásrendszerek esetén, mint például a kínai, japán és koreai.

### UTF-16

*Minden kódpont ábrázolása 2 vagy 4 byte-on történik (változó szélességű kódolás).*

- A BMP karaktereinek ábrázolása 2 byte-on, az összes többi pedig 4 byte-on.
- A BMP karaktereinek ábrázolására van optimalizálva.
- A BMP kódpontjainál rögzített szélességű kódolási formaként kezelhető.

Kompromisszumot képvisel a hatékony hozzáférés és a hatékony tárháználát között.

### UTF-32

*Minden kódpont ábrázolása 4 byte-on történik (rögzített szélességű kódolás).* Ez a legegyszerűbb karakterkódolás. Feldolgozás szempontjából ez a leghatékonyabb, azonban tárolás szempontjából a

legkevésbé hatékony.

További karakterkódolás

## ISO/IEC 8859-2 (Latin-2)

A közép-európai nyelvekhez. Az albán, bosnyák, cseh, horvát, lengyel, magyar, német, román, szerb (latin betűs írás), szlovák, szlovén, szorb nyelvekhez alkalmas.

## Unicode karakterek kifejezése

### CSS

Unicode karakterek megadásához használhatunk `\hhhhh` formájú vezérlősorozatokat, ahol hhhhh a Unicode karakter kódpontját ábrázoló legalább egy és legfeljebb 6 karakterből álló hexadecimális számjegysorozat.

```
\9, \09, \000009 - vízszintes tabulátor karaktert jeleníti meg  
\A9, \0A9, \0000A9 - a copyright szimbólumot jelenti
```

### JSON

Sztringekben a BMP-hez tartozó Unicode karakterek megadhatóak `\uhhhh` formájú vezérlősorozatokkal, ahol hhhh a kódpontot ábrázoló négy hexadecimális számjegy.

```
\u00A9, \u262F
```

### XML

**Szövegben, attribútumértékekben és literális egyed értékekben Unicode karakterek kifejezhetők az alábbi formájú karakterhivatkozásokkal:**

```
&#nnnn: ahol nnnn a kódpontot ábrázoló decimális számjegysorozat  
&#169, &#9775, &#128570
```

### HTML

Számos Unicode karakter fejezhető ki **&név;** formájú nevesített karakterhivatkozásokkal.

```
&Eacute; (U+00C9 = É)  
&eacute; (U+00E9 = é)  
&star; (U+2606 = csillag_rajz)
```